

Techniki Inteligentnej Analizy Danych

2025/2026

Zadanie 3 - Klasyfikacja obrazów

Filip Wasiel, 251658
Szymon Kaźmierczak, 251546

13 maja 2026

1 Cel projektu

Celem projektu jest zaprojektowanie, implementacja oraz ewaluacja systemu wizyjnego opartego na architekturze głębokich splotowych sieci neuronowych (CNN). Projekt koncentruje się na rozwiązaniu problemu wieloklasowej klasyfikacji obiektów cyfrowych, dążąc do uzyskania wysokiej precyzji rozpoznawania wzorców przy jednoczesnym zachowaniu optymalnej wydajności obliczeniowej.

2 Organizacja badań

Proces badawczy zrealizowano w formie zautomatyzowanego potoku przetwarzania danych, zapewniającego powtarzalność pomiarów dla różnych architektur sieciowych. Eksperymenty zostały zaprojektowane tak, aby umożliwić bezpośrednie porównanie modeli uczonych od podstaw z modelami wykorzystującymi uczenie transferowe.

2.1 Przygotowanie i podział danych

Proces zarządzania zasobami graficznymi realizowany jest przez moduł `data_manager.py`. Organizacja tego etapu obejmuje:

- **Selekcja danych:** Wybór 10 klas decyzyjnych przy zachowaniu sztywnego limitu 1000 obrazów na kategorię (`LIMIT_PER_CLASS`), co zapewnia pełne zbalansowanie zbiorów.
- **Podział na zbiory:** Dane są dzielone dynamicznie na podzbiór treninowy (*train*) oraz testowy (*test*). W celu zapewnienia rzetelności porównań, proces mieszania zdjęć realizowany jest przy użyciu stałego ziarna losowości (*Random Seed = 420*), co gwarantuje identyczny skład zbiorów dla każdego testowanego modelu.

2.2 Parametryzacja i środowisko testowe

W celu uzyskania miarodajnych wyników, wszystkie modele poddawane są testom przy zachowaniu ujednoliconych parametrów konfiguracyjnych zdefiniowanych w module `config.py`:

- **Wymiarowość wejścia:** Standaryzacja obrazów do rozdzielczości 128×128 pikseli.
- **Dynamika uczenia:** Proces prowadzony jest przez 20 epok z wykorzystaniem optymalizatora Adam.
 - **Plan eksperymentalny (Testowanie):** Każda z trzech architektur (*SimpleCNN*, *MobileNetV2*, *ResNet50*) została poddana serii testów weryfikujących wpływ liczności zbioru uczącego na jakość klasyfikacji. Proces ten zrealizowano poprzez iteracyjne trenowanie modeli dla różnych proporcji podziału danych (`train_splits`): [0.1, 0.3, 0.5, 0.7, 0.9].
 - **Walidacja krzyżowa parametrów:** Wszystkie próby testowe dla wymienionych podziałów przeprowadzono przy zachowaniu identycznego ziarna losowości (*seed*), co umożliwia bezpośrednie porównanie wyników różnych modeli wewnątrz tego samego wariantu podziału danych.
- **Obciążenie obliczeniowe:** Rozmiar paczki danych (*Batch Size*) ustalono na 128 próbek, co optymalizuje użycie pamięci VRAM procesorów graficznych przy zachowaniu stabilności estymacji gradientu.

2.3 Przebieg eksperymentu

Trening modeli odbywa się w odizolowanym wątku systemowym, co separuje obliczenia numeryczne od warstwy prezentacji. Proces ładowania danych wykorzystuje mechanizmy `.cache()` oraz `.prefetch()`, co pozwala na asynchroniczne przygotowywanie danych przez CPU podczas pracy jednostki GPU, minimalizując czasy przestoju.

2.4 Archiwizacja i struktura wyników

Po zakończeniu fazy uczenia i automatycznej ewaluacji przez moduł `evaluate.py`, komplet wyników jest zapisywany w dedykowanej strukturze folderów w katalogu `results/`. Każdy raport z badania zawiera:

- **Dane surowe (JSON):** Zbiór metryk statystycznych, w tym dokładność, precyzję oraz czułość dla każdej klasy.
- **Wizualizacje (PNG):** Wykresy przebiegu funkcji straty i dokładności w dziedzinie epok oraz graficzną macierz pomyłek (*Confusion Matrix*).
- **Raport tekstowy (TXT):** Szczegółowe zestawienie wydajności klasyfikacji z uwzględnieniem miar F1-Score.

3 Opis zbioru danych

W projekcie wykorzystano zbiór danych wizyjnych Food-101, który został poddany procesowi selekcji i standaryzacji w celu zapewnienia wysokiej jakości procesu uczenia.

3.1 Charakterystyka ilościowa i struktura

Zbiór danych został zbalansowany pod kątem liczności klas, aby uniknąć faworyzowania kategorii przez model:

- **Klasy decyzyjne:** Do eksperymentu wybrano 10 kategorii (*apple_pie*, *hamburger*, *chicken_curry*, *donuts*, *french_fries*, *ice_cream*, *pizza*, *tacos*, *omelette*, *beef_carpaccio*).
- **Liczność próbek:** Zastosowano limit `LIMIT_PER_CLASS` wynoszący 1000 obrazów na każdą klasę, co daje łącznie do 10 000 próbek w zbiorze bazowym.
- **Formatowanie:** Obrazy są standaryzowane do rozdzielczości 128×128 pikseli w przestrzeni barwnej RGB.

3.2 Przetwarzanie wstępne (Preprocessing)

Przed fazą uczenia dane przechodzą przez automatyczny potok przetwarzania:

1. **Normalizacja:** Wartości pikseli są skalowane z zakresu $[0, 255]$ do $[0, 1]$ (*rescaling*), co stabilizuje proces optymalizacji wag.
2. **Augmentacja:** W trakcie treningu stosowane są losowe transformacje (odbicia i rotacje), zwiększające zdolność modelu do generalizacji cech.

4 Opis modeli

4.1 SimpleCNN

Model *SimpleCNN* jest autorską, sekwencyjną siecią splotową zaprojektowaną do uczenia od podstaw (from scratch). Architektura opiera się na klasycznym wzorcu wydobywania cech z progresywnym zwiększaniem liczby filtrów.

- **Ekstrakcja cech:** Składa się z trzech bloków splotowych. Każdy blok zawiera warstwę `Conv2D` z funkcją aktywacji *ReLU* oraz warstwę `MaxPooling2D` do redukcji wymiarowości przestrzennej.
- **Stabilizacja i regularyzacja:** Wewnątrz bloków zastosowano warstwy `BatchNormalization` w celu przyspieszenia konwergencji oraz warstwę `Dropout` (0.5) przed warstwą wyjściową, co ogranicza ryzyko przeuczenia.
- **Klasyfikator:** Zastosowano spłaszczenie tensora (`Flatten`) oraz gęstą warstwę `Dense`, kończącą się aktywacją *Softmax* dla 10 klas decyzyjnych.

4.2 MobileNetV2

Model ten wykorzystuje technikę uczenia transferowego (Transfer Learning), bazując na architekturze zoptymalizowanej pod kątem wydajności obliczeniowej.

- **Baza modelu:** Wykorzystano wagę pretrenowaną na zbiorze *ImageNet*. Zgodnie z implementacją, warstwy bazowe zostały zamrożone (`trainable = False`), co pozwala na wykorzystanie wyuczonych generycznych cech wizualnych.
- **Mechanizm zamrażania wag:** Ustawienie parametru `trainable = False` oznacza, że podczas procesu optymalizacji wagi warstw bazowych pozostają niezmiennie. Dzięki temu procesowi trenowania podlega wyłącznie nowo dodana warstwa wyjściowa (klasyfikator), co zapobiega utracie wcześniej wyuczonych cech uniwersalnych i drastycznie przyspiesza obliczenia.
- **Preprocessing:** Model zawiera dedykowaną warstwę `Lambda` realizującą specyficzne dla MobileNetV2 przetwarzanie wstępne sygnału wejściowego.
- **Agregacja cech:** Zamiast klasycznych warstw gęstych o dużej liczbie parametrów, zastosowano warstwę `GlobalAveragePooling2D`, co drastycznie redukuje rozmiar modelu i ryzyko overfittingu.

4.3 ResNet50

Ostatnia z badanych architektur to głęboka sieć rezidualna, znana z wykorzystania połączeń skrótowych (*skip connections*), które rozwiązują problem zanikającego gradientu.

- **Struktura bazowa i Transfer Learning:** Podobnie jak w przypadku MobileNetV2, zastosowano uczenie transferowe z wagami *ImageNet*. Warstwy bazowe są zamrożone, co oznacza, że model wykorzystuje gotowe filtry do rozpoznawania kształtów i tekstur, a uczona jest jedynie końcowa warstwa gęsta dopasowana do 10 klas potraw.
- **Konfiguracja głowy modelu:** Wyjście z bloków rezidualnych jest przetwarzane przez warstwę `GlobalAveragePooling2D`, a następnie przez warstwę `Dropout` (0.4) i końcowy klasyfikator gęsty.
- **Optymalizacja:** Ze względu na dużą głębokość sieci, model został skonfigurowany z obniżonym współczynnikiem uczenia (*Learning Rate* = 0.0001), co zapewnia stabilną adaptację wag klasyfikatora bez ryzyka destabilizacji parametrów modelu bazowego.

5 Miary oceny jakości modeli

Ewaluacja modeli opiera się na analizie wyników uzyskanych na zbiorze testowym. Do oceny skuteczności systemu klasyfikacji wykorzystano zestaw miar,

które pozwalają określić sprawność algorytmu w rozpoznawaniu 10 różnych kategorii obiektów.

5.1 Wskaźniki skuteczności

W raporcie zastosowano cztery podstawowe wskaźniki, które interpretowane są w następujący sposób:

- **Dokładność (Accuracy):** Określa stosunek liczby wszystkich poprawnych predykcji do całkowitej liczby próbek w zbiorze testowym. Jest to ogólny miernik poprawności systemu, informujący o tym, jak często model podaje właściwą etykietę.
- **Precyzja (Precision):** Określa stosunek liczby poprawnie rozpoznanych obrazów danej klasy do wszystkich obrazów, które model zaklasyfikował do tej kategorii. Wysoka wartość oznacza, że jeśli model wskazał konkretną potrawę, to w większości przypadków ma rację, a liczba błędnych wskazań (*pomyłek z innymi klasami*) jest niewielka.
- **Czułość (Recall):** Określa stosunek liczby poprawnie rozpoznanych obrazów danej klasy do wszystkich obrazów, które faktycznie do niej należą. Wysoka wartość czułości świadczy o tym, że model skutecznie odnajduje większość próbek danej klasy i rzadko pomija je na rzecz innych etykiet.
- **F1-Score:** Średnia harmoniczna precyzji i czułości, stanowiąca wypadkową obu tych miar. Pozwala na ocenę balansu modelu – wysoka wartość F1-Score gwarantuje, że model jest jednocześnie wiarygodny w swoich wskazaniach (wysoka precyzja) i nie pomija istotnej części zbioru danych (wysoka czułość).

5.2 Analiza graficzna

Uzupełnieniem miar liczbowych są narzędzia pozwalające na identyfikację konkretnych błędów systemu:

- **Macierz pomyłek (Confusion Matrix):** Tabela zestawiona w formie graficznej, która pokazuje, jakie klasy są ze sobą najczęściej mylone.
- **Wykresy historii uczenia:** Wykresy pokazujące, jak zmieniała się skuteczność modelu z epoki na epokę. Pozwalają ocenić, czy model nadal się uczy, czy też osiągnął już swój limit możliwości przy danej architekturze.

6 Wyniki

W niniejszym rozdziale przedstawiono szczegółowe wyniki uzyskane podczas eksperymentów dla każdej z trzech architektur. Analiza obejmuje zestawienie metryk ilościowych oraz wizualizację procesu uczenia i błędów klasyfikacji dla różnych wariantów podziału zbioru danych.

6.1 Model: SimpleCNN


Model SimpleCNN, uczony od podstaw na standaryzowanym zbiorze danych, posłużył jako punkt odniesienia dla pozostałych architektur wykorzystujących uczenie transferowe.

6.1.1 Podział: 10% uczący / 90% testowy


W wariancie niskiej dostępności danych treningowych model uzyskał dokładność na poziomie **24,02%**.

Tabela 1: Metryki klasyfikacji dla modelu SimpleCNN przy podziale 10/90

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.17	0.17	0.17	900
beef_carpaccio	0.48	0.38	0.43	900
chicken_curry	0.24	0.19	0.21	900
donuts	0.17	0.26	0.20	900
french_fries	0.27	0.39	0.32	900
hamburger	0.17	0.17	0.17	900
ice_cream	0.28	0.33	0.30	900
omelette	0.23	0.26	0.24	900
pizza	0.24	0.09	0.13	900
tacos	0.23	0.17	0.20	900
Weighted Avg	0.25	0.24	0.24	9000



Rysunek 1: Macierz pomyłek dla modelu SimpleCNN (podział 10/90)




Rysunek 2: Wykres dokładności dla modelu SimpleCNN (podział 10/90)

6.1.2 Podział: 30% uczący / 70% testowy


Zwiększenie zbioru uczącego do 30% przełożyło się na wzrost dokładności do poziomu **27,31%**.

Tabela 2: Metryki klasyfikacji dla modelu SimpleCNN przy podziale 30/70

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.23	0.15	0.18	700
beef_carpaccio	0.44	0.64	0.52	700
chicken_curry	0.24	0.44	0.31	700
donuts	0.21	0.20	0.21	700
french_fries	0.43	0.14	0.21	700
hamburger	0.23	0.19	0.21	700
ice_cream	0.28	0.27	0.28	700
omelette	0.21	0.14	0.17	700
pizza	0.30	0.18	0.23	700
tacos	0.23	0.38	0.29	700
Weighted Avg	0.28	0.27	0.26	7000



Rysunek 3: Macierz pomyłek dla modelu SimpleCNN (podział 30/70)




Rysunek 4: Wykres dokładności dla modelu SimpleCNN (podział 30/70)

6.1.3 Podział: 50% uczący / 50% testowy


Przy równym podziale danych model osiągnął wynik **30,78%**.

Tabela 3: Metryki klasyfikacji dla modelu SimpleCNN przy podziale 50/50

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.21	0.13	0.16	500
beef_carpaccio	0.44	0.64	0.52	500
chicken_curry	0.33	0.32	0.33	500
donuts	0.24	0.33	0.28	500
french_fries	0.40	0.36	0.38	500
hamburger	0.25	0.12	0.16	500
ice_cream	0.31	0.33	0.32	500
omelette	0.23	0.32	0.26	500
pizza	0.31	0.35	0.33	500
tacos	0.30	0.18	0.22	500
Weighted Avg	0.30	0.31	0.30	5000



Rysunek 5: Macierz pomyłek dla modelu SimpleCNN (podział 50/50)




Rysunek 6: Wykres dokładności dla modelu SimpleCNN (podział 50/50)

6.1.4 Podział: 70% uczący / 30% testowy


Dla podziału 70/30 model uzyskał dokładność **32,70%**.

Tabela 4: Metryki klasyfikacji dla modelu SimpleCNN przy podziale 70/30

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.21	0.30	0.25	300
beef_carpaccio	0.54	0.59	0.57	300
chicken_curry	0.30	0.37	0.33	300
donuts	0.30	0.28	0.29	300
french_fries	0.39	0.41	0.40	300
hamburger	0.24	0.15	0.18	300
ice_cream	0.36	0.40	0.38	300
omelette	0.26	0.32	0.28	300
pizza	0.37	0.21	0.27	300
tacos	0.32	0.23	0.27	300
Weighted Avg	0.33	0.33	0.32	3000



Rysunek 7: Macierz pomyłek dla modelu SimpleCNN (podział 70/30)




Rysunek 8: Wykres dokładności dla modelu SimpleCNN (podział 70/30)

6.1.5 Podział: 90% uczący / 10% testowy


Przy największym zbiorze treningowym model osiągnął wynik **33,80%**.

Tabela 5: Metryki klasyfikacji dla modelu SimpleCNN przy podziale 90/10

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.26	0.23	0.24	100
beef_carpaccio	0.52	0.68	0.59	100
chicken_curry	0.36	0.41	0.38	100
donuts	0.28	0.23	0.25	100
french_fries	0.48	0.20	0.28	100
hamburger	0.24	0.29	0.26	100
ice_cream	0.35	0.26	0.30	100
omelette	0.26	0.36	0.31	100
pizza	0.46	0.39	0.42	100
tacos	0.27	0.33	0.30	100
Weighted Avg	0.35	0.34	0.33	1000



Rysunek 9: Macierz pomyłek dla modelu SimpleCNN (podział 90/10)



Rysunek 10: Wykres dokładności dla modelu SimpleCNN (podział 90/10)

6.2 Model: MobileNetV2


Model MobileNetV2 został wykorzystany w ramach techniki uczenia transferowego (Transfer Learning) z zamrożonymi wagami bazowymi. Zastosowanie pretrenowanej architektury pozwoliło na uzyskanie znacząco wyższych wskaźników precyzji w porównaniu do modelu SimpleCNN, nawet przy niewielkich zbiorach treningowych.

6.2.1 Podział: 10% uczący / 90% testowy


Przy wykorzystaniu zaledwie 10% danych do treningu, model osiągnął wysoką dokładność na poziomie **74,73%**. Szczegółowe zestawienie metryk przedstawia Tabela 6.

Tabela 6: Metryki klasyfikacji dla modelu MobileNetV2 przy podziale 10/90

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.65	0.60	0.63	900
beef_carpaccio	0.77	0.84	0.80	900
chicken_curry	0.74	0.67	0.70	900
donuts	0.79	0.75	0.77	900
french_fries	0.90	0.86	0.88	900
hamburger	0.82	0.77	0.79	900
ice_cream	0.69	0.82	0.75	900
omelette	0.62	0.64	0.63	900
pizza	0.83	0.85	0.84	900
tacos	0.68	0.67	0.68	900
Weighted Avg	0.75	0.75	0.75	9000



Rysunek 11: Macierz pomyłek dla modelu MobileNetV2 (podział 10/90)




Rysunek 12: Wykres dokładności dla modelu MobileNetV2 (podział 10/90)

6.2.2 Podział: 30% uczący / 70% testowy


Zwiększenie zbioru treningowego do 30% poskutkowało wzrostem ogólnej dokładności do poziomu **78,17%**.

Tabela 7: Metryki klasyfikacji dla modelu MobileNetV2 przy podziale 30/70

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.65	0.71	0.68	700
beef_carpaccio	0.80	0.88	0.84	700
chicken_curry	0.78	0.72	0.75	700
donuts	0.82	0.80	0.81	700
french_fries	0.88	0.89	0.89	700
hamburger	0.83	0.79	0.81	700
ice_cream	0.78	0.80	0.79	700
omelette	0.66	0.67	0.66	700
pizza	0.86	0.85	0.85	700
tacos	0.75	0.70	0.72	700
Weighted Avg	0.78	0.78	0.78	7000



Rysunek 13: Macierz pomyłek dla modelu MobileNetV2 (podział 30/70)




Rysunek 14: Wykres dokładności dla modelu MobileNetV2 (podział 30/70)

6.2.3 Podział: 50% uczący / 50% testowy


Przy równym podziale danych model utrzymał stabilny wynik na poziomie **78,40%** dokładności.

Tabela 8: Metryki klasyfikacji dla modelu MobileNetV2 przy podziale 50/50

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.69	0.68	0.68	500
beef_carpaccio	0.85	0.84	0.85	500
chicken_curry	0.81	0.71	0.75	500
donuts	0.82	0.80	0.81	500
french_fries	0.90	0.89	0.90	500
hamburger	0.83	0.80	0.81	500
ice_cream	0.73	0.86	0.79	500
omelette	0.66	0.69	0.68	500
pizza	0.83	0.85	0.84	500
tacos	0.74	0.71	0.73	500
Weighted Avg	0.79	0.78	0.78	5000



Rysunek 15: Macierz pomyłek dla modelu MobileNetV2 (podział 50/50)




Rysunek 16: Wykres dokładności dla modelu MobileNetV2 (podział 50/50)

6.2.4 Podział: 70% uczący / 30% testowy


Dla podziału 70/30 model uzyskał optymalny wynik dokładności wynoszący **79,33%**.

Tabela 9: Metryki klasyfikacji dla modelu MobileNetV2 przy podziale 70/30

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.71	0.70	0.70	300
beef_carpaccio	0.86	0.84	0.85	300
chicken_curry	0.81	0.72	0.76	300
donuts	0.81	0.85	0.83	300
french_fries	0.90	0.90	0.90	300
hamburger	0.85	0.78	0.81	300
ice_cream	0.76	0.83	0.79	300
omelette	0.71	0.67	0.69	300
pizza	0.84	0.85	0.85	300
tacos	0.70	0.80	0.74	300
Weighted Avg	0.80	0.79	0.79	3000



Rysunek 17: Macierz pomyłek dla modelu MobileNetV2 (podział 70/30)




Rysunek 18: Wykres dokładności dla modelu MobileNetV2 (podział 70/30)

6.2.5 Podział: 90% uczący / 10% testowy


Przy największym zbiorze treningowym model uzyskał wynik **79,00%**. Mimo zwiększenia ilości danych, wynik pozostał zbliżony do wariantu 70/30, co sugeruje nasycenie modelu przy zamrożonych wagach bazowych.

Tabela 10: Metryki klasyfikacji dla modelu MobileNetV2 przy podziale 90/10

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.67	0.66	0.66	100
beef_carpaccio	0.89	0.84	0.87	100
chicken_curry	0.74	0.79	0.76	100
donuts	0.83	0.83	0.83	100
french_fries	0.92	0.88	0.90	100
hamburger	0.84	0.78	0.81	100
ice_cream	0.81	0.79	0.80	100
omelette	0.70	0.73	0.71	100
pizza	0.81	0.87	0.84	100
tacos	0.73	0.73	0.73	100
Weighted Avg	0.79	0.79	0.79	1000



Rysunek 19: Macierz pomyłek dla modelu MobileNetV2 (podział 90/10)



Rysunek 20: Wykres dokładności dla modelu MobileNetV2 (podział 90/10)

6.3 Model: ResNet50


Ostatnim z badanych rozwiązań jest model ResNet50, wykorzystujący architekturę rezidualną w ramach uczenia transferowego. Podobnie jak w przypadku MobileNetV2, zastosowano strategię zamrożonych wag bazowych, koncentrując proces optymalizacji na końcowej warstwie klasyfikacyjnej.

6.3.1 Podział: 10% uczący / 90% testowy


W wariancie z najmniejszą ilością danych treningowych model ResNet50 uzyskał dokładność na poziomie **51,90%**[cite: 55]. Szczegółowe metryki dla tego podziału przedstawia Tabela 11.

Tabela 11: Metryki klasyfikacji dla modelu ResNet50 przy podziale 10/90

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.42	0.34	0.37	900 [cite: 51]
beef_carpaccio	0.55	0.55	0.55	900 [cite: 51]
chicken_curry	0.51	0.44	0.47	900 [cite: 51, 52]
donuts	0.62	0.60	0.61	900 [cite: 52]
french_fries	0.76	0.78	0.77	900 [cite: 52]
hamburger	0.50	0.47	0.49	900 [cite: 52, 53]
ice_cream	0.47	0.61	0.53	900 [cite: 53]
omelette	0.39	0.33	0.36	900 [cite: 53]
pizza	0.56	0.69	0.62	900 [cite: 53, 54]
tacos	0.37	0.39	0.38	900 [cite: 54]
Weighted Avg	0.52	0.52	0.51	9000 [cite: 55]



Rysunek 21: Macierz pomyłek dla modelu ResNet50 (podział 10/90)




Rysunek 22: Wykres dokładności dla modelu ResNet50 (podział 10/90)

6.3.2 Podział: 30% uczący / 70% testowy


Zwiększenie wolumenu danych treningowych do 30% zaowocowało wyraźnym wzrostem dokładności do poziomu **66,17%**[cite: 60].

Tabela 12: Metryki klasyfikacji dla modelu ResNet50 przy podziale 30/70

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.53	0.52	0.52	700 [cite: 56]
beef_carpaccio	0.71	0.77	0.74	700 [cite: 56]
chicken_curry	0.67	0.57	0.62	700 [cite: 56, 57]
donuts	0.74	0.73	0.74	700 [cite: 57]
french_fries	0.84	0.85	0.85	700 [cite: 57]
hamburger	0.66	0.65	0.65	700 [cite: 57, 58]
ice_cream	0.66	0.69	0.67	700 [cite: 58]
omelette	0.51	0.50	0.50	700 [cite: 58]
pizza	0.74	0.78	0.76	700 [cite: 58, 59]
tacos	0.55	0.56	0.56	700 [cite: 59]
Weighted Avg	0.66	0.66	0.66	7000 [cite: 60]



Rysunek 23: Macierz pomylek dla modelu ResNet50 (podział 30/70)




Rysunek 24: Wykres dokładności dla modelu ResNet50 (podział 30/70)

6.3.3 Podział: 50% uczący / 50% testowy


Przy równym rozkładzie danych treningowych i testowych model uzyskał dokładność **69,42%**[cite: 65].

Tabela 13: Metryki klasyfikacji dla modelu ResNet50 przy podziale 50/50

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.58	0.54	0.56	500 [cite: 61]
beef_carpaccio	0.73	0.80	0.76	500 [cite: 61]
chicken_curry	0.71	0.63	0.67	500 [cite: 61, 62]
donuts	0.76	0.76	0.76	500 [cite: 62]
french_fries	0.85	0.88	0.87	500 [cite: 62]
hamburger	0.70	0.64	0.67	500 [cite: 62, 63]
ice_cream	0.68	0.72	0.70	500 [cite: 63]
omelette	0.57	0.56	0.57	500 [cite: 63]
pizza	0.75	0.80	0.77	500 [cite: 63, 64]
tacos	0.58	0.59	0.59	500 [cite: 64]
Weighted Avg	0.69	0.69	0.69	5000 [cite: 65]



Rysunek 25: Macierz pomyłek dla modelu ResNet50 (podział 50/50)




Rysunek 26: Wykres dokładności dla modelu ResNet50 (podział 50/50)

6.3.4 Podział: 70% uczący / 30% testowy


Dla podziału 70/30 odnotowano szczytową wydajność modelu ResNet50, wynoszącą **72,93%** dokładności[cite: 70].

Tabela 14: Metryki klasyfikacji dla modelu ResNet50 przy podziale 70/30

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.60	0.64	0.62	300 [cite: 66]
beef_carpaccio	0.77	0.82	0.80	300 [cite: 66]
chicken_curry	0.72	0.68	0.70	300 [cite: 66, 67]
donuts	0.78	0.76	0.77	300 [cite: 67]
french_fries	0.86	0.87	0.86	300 [cite: 67]
hamburger	0.78	0.69	0.73	300 [cite: 67, 68]
ice_cream	0.71	0.73	0.72	300 [cite: 68]
omelette	0.61	0.62	0.61	300 [cite: 68]
pizza	0.83	0.80	0.81	300 [cite: 68, 69]
tacos	0.65	0.68	0.67	300 [cite: 69]
Weighted Avg	0.73	0.73	0.73	3000 [cite: 70]



Rysunek 27: Macierz pomylek dla modelu ResNet50 (podział 70/30)




Rysunek 28: Wykres dokładności dla modelu ResNet50 (podział 70/30)

6.3.5 Podział: 90% uczący / 10% testowy


Przy maksymalnym zbiorze treningowym model osiągnął wynik **72,90%**[cite: 75]. Brak dalszego wzrostu względem podziału 70/30 sugeruje nasycenie procesu adaptacji głowy modelu przy zamrożonych wagach części bazowej.

Tabela 15: Metryki klasyfikacji dla modelu ResNet50 przy podziale 90/10

Klasa potrawy	Precyzja	Czułość	F1-Score	Wsparcie
apple_pie	0.70	0.59	0.64	100 [cite: 71]
beef_carpaccio	0.79	0.84	0.81	100 [cite: 71]
chicken_curry	0.71	0.69	0.70	100 [cite: 71, 72]
donuts	0.75	0.78	0.76	100 [cite: 72]
french_fries	0.86	0.85	0.85	100 [cite: 72]
hamburger	0.74	0.67	0.71	100 [cite: 72, 73]
ice_cream	0.69	0.75	0.72	100 [cite: 73]
omelette	0.61	0.61	0.61	100 [cite: 73]
pizza	0.76	0.81	0.79	100 [cite: 73, 74]
tacos	0.67	0.70	0.68	100 [cite: 74]
Weighted Avg	0.73	0.73	0.73	1000 [cite: 75]



Rysunek 29: Macierz pomyłek dla modelu ResNet50 (podział 90/10)



Rysunek 30: Wykres dokładności dla modelu ResNet50 (podział 90/10)

7 Porównanie modeli i analiza wyników

W niniejszym rozdziale dokonano zestawienia wyników uzyskanych przez trzy badane architektury: autorską sieć Simple CNN oraz dwa modele wykorzystujące uczenie transferowe – MobileNetV2 i ResNet50. Porównanie obejmuje wpływ wielkości zbioru treningowego na precyzję klasyfikacji oraz analizę zachowania modeli w kontekście różnych kategorii potraw.

7.1 Zbiorcze zestawienie dokładności (Accuracy)

Tabela 16 przedstawia zbiorcze wyniki dokładności dla wszystkich modeli w zależności od zastosowanego podziału danych na zbiór uczący i testowy.

Tabela 16: Porównanie dokładności (Accuracy) badanych modeli

Podział (Train/Test)	Simple CNN	MobileNetV2	ResNet50
10% / 90%	24,02%	74,73%	51,90%
30% / 70%	27,31%	78,17%	66,17%
50% / 50%	30,78%	78,40%	69,42%
70% / 30%	32,70%	79,33%	72,93%
90% / 10%	33,80%	79,00%	72,90%

7.2 Wnioski z porównania architektur

- **Przewaga uczenia transferowego:** Modele MobileNetV2 oraz ResNet50 znacząco przewyższają autorską sieć Simple CNN (o około 40–45 punktów procentowych). Potwierdza to hipotezę, że dla złożonych zbiorów obrazów, takich jak Food-101, wykorzystanie wag pre-trenowanych na zbiorze ImageNet jest kluczowe dla uzyskania satysfakcjonujących wyników.
- **Wydajność MobileNetV2:** Najlepsze wyniki w całym badaniu uzyskał model MobileNetV2. Jest to zjawisko interesujące, biorąc pod uwagę, że jest to architektura lżejsza niż ResNet50. Sugeruje to, że cechy wyekstrahowane przez MobileNetV2 lepiej korelują ze specyfiką wizualną badanych potraw lub model ten jest mniej podatny na przeuczenie przy zastosowanej strategii zamrożonych wag.
- **Stabilność wyników:** Modele oparte na uczeniu transferowym wykazały dużą odporność na małą ilość danych treningowych. Już przy 10% danych uczących MobileNetV2 osiągnął wynik (74,73%), który był bliski jego wynikowi maksymalnemu. Prosta sieć CNN wymagała znacznie większych zbiorów, a jej progresja była liniowa, lecz powolna.

7.3 Analiza klasyfikacji poszczególnych potraw

Na podstawie szczegółowych raportów klasyfikacji (F1-Score) można sformułować następujące obserwacje dotyczące trudności rozpoznawania konkretnych klas:

1. **Klasy o wysokiej rozpoznawalności:** We wszystkich modelach najwyższe wyniki (często przekraczające 85–90%) odnotowano dla klasy *french_fries*. Prawdopodobnie wynika to z unikalnej tekstury i powtarzalnej kolorystyki frytek, co ułatwia ekstrakcję cech. Dobrze klasyfikowane były również *beef_carpaccio* oraz *pizza*.

2. **Klasy problematyczne:** Największe trudności modele miały z klasami *apple_pie*, *omelette* oraz *tacos*. Potrawy te charakteryzują się dużą zmiennością wizualną (różne sposoby podania, nakładające się składniki), co prowadzi do pomyłek, najczęściej z potrawami o podobnej paletce barw lub strukturze (np. omlet z pizzą).

7.4 Wnioski końcowe

Przeprowadzone badania pozwalają na sformułowanie następujących wniosków:

1. Do zadania rozpoznawania potraw na podstawie zdjęć zdecydowanie zaleca się stosowanie metod uczenia transferowego. Autorskie, proste architektury CNN wymagają znacznie większych zbiorów danych i bardziej zaawansowanej optymalizacji, aby zbliżyć się do wydajności gotowych modeli.
2. Model MobileNet V2 stanowi optymalny wybór w zadaniu klasyfikacji podzbioru Food-101, oferując najwyższą dokładność przy jednoczesnej efektywności obliczeniowej.
3. Zwiększanie zbioru treningowego powyżej 70% dla modeli pre-trenowanych (przy zamrożonej bazie) daje marginalne zyski, co wskazuje na to, że bariera błędu leży bardziej w samej architekturze klasyfikatora lub jakości zdjęć, niż w ilości dostępnych przykładów.